输出更可靠了，检错仍未解决

ReVALUE 实验进度与结果

阶段： 2026.10.30—11.03

8B： 273 / 278 条输出合法

98.20%

价值引导收益尚未确立

8B： 278/278 次完成

32B： 前 20 条完成， 74/74 次；未改善

来源：最新实验进度报告（2026-11-03）｜主线： grounding ｜包含 32B 配对结果

基线定位区间，verifier 检查内容条件

视频 + query

整视频输入

→

REZE Direct

一次输出区间列表

→

候选区间

98 条有效 query

→

Q / Q+V verifier

可见事实 → 证据引用 → 条件判断

supported / flagged

insufficient

冻结条件 + 候选帧

100 query · 139 区间 · 两组共享帧与 PTS

→

尚待验证：定向回看、边界检查与区间修正

当前没有形成完整 grounding 闭环；原区间、顺序和分数未改写。

来源：实验进度与结果报告 §1–3 ｜快照 2026-11-02 23:56

REZE Direct 已固定，指标尚无一致优势

QVHighlights train · 固定 100 条开发样本 · 指标单位 %

指标	自定义 Direct	REZE Direct
R1@0.5	42.00	**39.00**
R1@0.7	28.00	**30.00**
MR mAP （0.5:0.05:0.95）	24.72	**26.48**

冻结 REZE Direct，作为后续验证参照

帧数、提示和输出形式同时变化；这不是单变量比较，也不是独立测试集。

来源：实验进度与结果报告 §2； REZE Direct QV100 结果报告（2026-10-30）

从相关工作到“可核查的价值证据”

五类视角沿用 ReVALUE；借鉴论文的方法，将抽象字段转为具体检查项。

VisionReward
多维偏好拆成判断题

→ **为每一视角给出可观察的判据**
支持 / 反证 / 缺证 / 禁止推断；未接入奖励权重。

UnifiedReward-Flex
根据输入细化评价标准

→ **只启用 query 相关的价值视角**
候选核查前冻结条件，不额外要求“精彩”或“成功”。

DSG
原子问题与依赖图

→ **检查对象、属性、动作是否正确绑定**
保留条件依赖；增加 unknown 、帧引用与时间作用域。

VTune
定位后验证事件与组成条件

→ **在 Direct 候选后加入逐条件 verifier**
单独评估验证可靠性；当前没有执行论文中的训练。

Query 条件 → 适用题库 → 事实 + 帧引用 → 支持 / 反证 / 未知
Q / Q+V 检验价值提示的额外贡献；当前收益尚未确立。

论文： arXiv 2412.21059 、 2602.02380 、 2411.12951 ； DSG： google.github.io/dsg/ ｜链接见讲稿

价值引导是 Q 与 Q+V 的主要差异

Q / 通用条件核验

从 query 拆出人物、物体、动作、关系，
判断每个必要条件是否有证据支持。

检查对象：内容是否符合 query

Q+V / 加入适用价值指导

补充支持、反证、缺证与禁止推断说明。

结果　信息　情绪　动作　感官

五维按条件映射，不另算加权总分

共享输入与验收

候选 · 帧 / PTS · 8B 模型 · query 条件 · schema · 验收规则

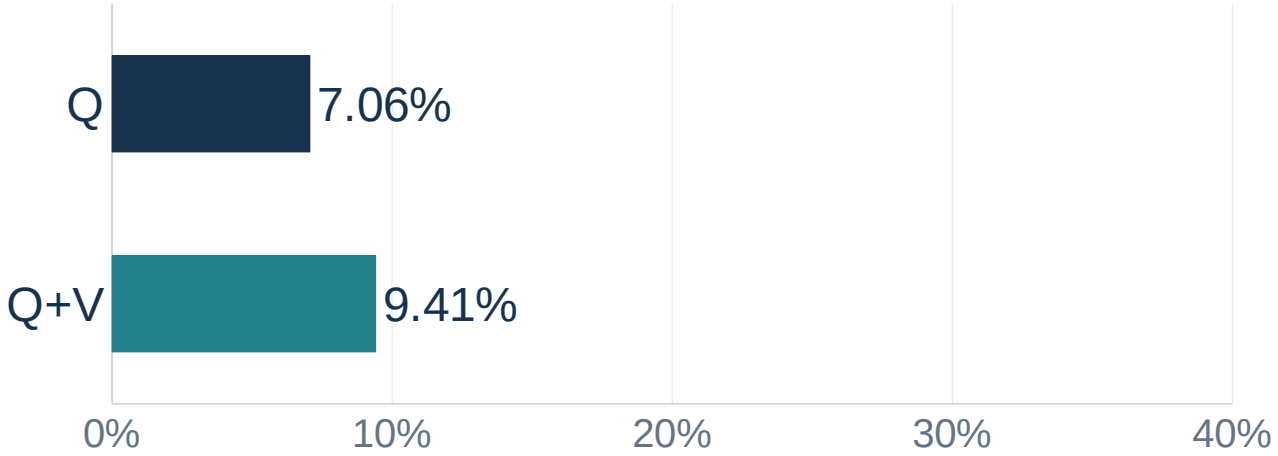
139 × 2 = 278 次调用，零重试。 两组均不改写区间。

条件由助手仅根据 query 构建，尚无独立人工审校； not_applicable 不代表漏检。

来源：实验进度与结果报告 §3.1 ｜ Q/Q+V v2.4 ，固定 QV100

Q+V 多检出 2 个，同时净增 1 个误报

错误召回率 · 每组 139 候选： 85 个低 IoU 代理错误， 54 个代理正确



报警数量仍少

Q： 检出 6 / 误报 1
精确率 85.71%

Q+V： 检出 8 / 误报 2
精确率 80.00%

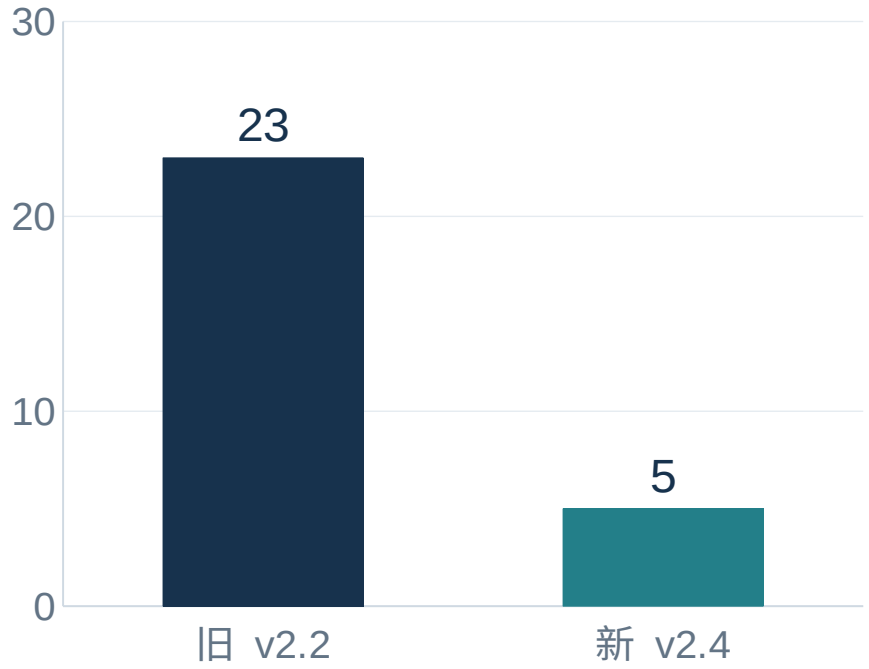
价值收益尚未确立；两组均未通过原探索性门槛

低 IoU 不必然是内容错误，尚无独立人工语义标签。

来源：实验进度与结果报告 §3.2 ｜代理错误定义：与任一 GT 的最大 IoU < 0.5

无效输出降至 5 条，去重贡献需单列

同验收口径比较 · 两轮均为 278 条响应



本轮归一化的贡献

52 → 5

原始严格无效 → 去重后仍无效

普通重复引用去重，恢复 47 条

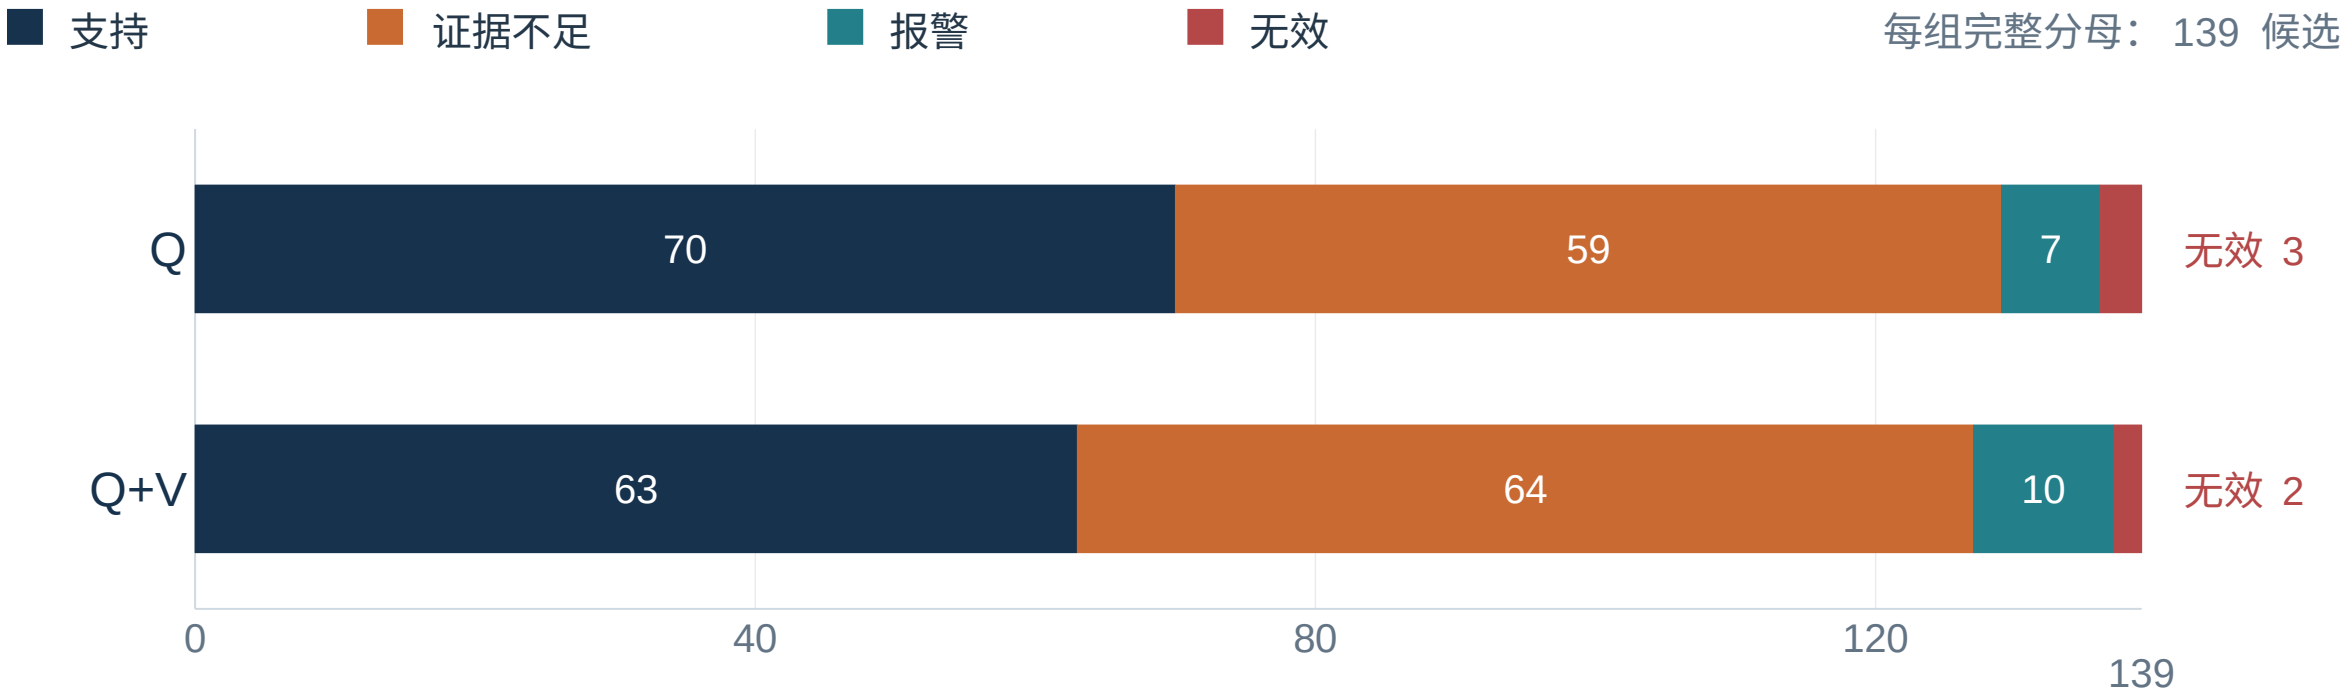
仍严格检查未定义引用、重复事实定义与时间顺序所需的有序证据。

绑定、依赖、生成顺序和去重共同变化，非单因素归因。

剩余 5 条： 2 条 JSON 截断 + 3 条有序事实不足

来源：实验进度与结果报告 §3.3 | 合法性改善不等于语义判断能力提高

超过四成候选仍停留在证据不足



不足比例： Q 42.45% / Q+V 46.04%； 尚无补证闭环

supported 中低 IoU： 41/70 、 32/63 。不能全部认定语义漏检，仍需审查边界与标注。

来源：实验进度与结果报告 §3–4 | unknown 不能直接转为错误

32B 已完成，同样本上更趋于“不判断”

同 20 条 query · 每臂 37 候选： 25 个代理错误 / 12 个代理正确

条件	支持	证据不足	无效	TP / FP	错误召回
8B Q	23	11	1	2 / 0	8.00%
8B Q+V	17	16	0	4 / 0	**16.00%**
32B Q	0	32	4	1 / 0	**4.00%**
32B Q+V	0	33	4	0 / 0	**0.00%**

32B： 65/74 次证据不足； Q+V 无报警，精确率未定义

74/74 次已完成， 66 条合法。输入一致，但三卡运行配置与 8B 单卡不同。
这是原清单前 20 条；不能推广到完整 100 条，也不能把零误报当作更好。

来源： 32B scope20 与 8B 同样本评价（2026-11-03）｜低 IoU 是错误代理

32B 的空泛事实会传到后续判断

QID 2781 · Q 组 · 候选 [37,41) 秒 · 同一批 16 帧

Query: Guys throw boomerangs at targets inside a gymnasium.

32B / 保存的原始事实

The required evidence is not available.

引用片后 f0089 （44.745s）；三个条件 unknown 。

正常 stop， 378 token；不是截断或前端丢字。

8B / 两条具体描述

人物投掷；目标处出现黄色烟雾。

引用片内 37.237s / 39.740s；模型判为支持。

描述仍待语义核验；该候选 IoU = 0 。

32B 有 25/74 条非空 facts 仅含固定套话； 8B 为 0

CPU 复现：无片内事实 → schema 只允许 unknown；最初为何这样生成仍未知。

提示示例、结构约束或运行配置的影响仍是待检验假设。

套话按三种字符串精确匹配，含 invalid 中可解析字段；不代表事实准确率。原始响应与 CPU 探针均保留。

来源： 32B 事实生成离线诊断（2026-11-03）｜零新增实验模型调用

引用合法，仍可能跨越语义证据

Query 要求：男子横持手机，阅读**文章**

模型描述（未人工核验）

可读文字

带字幕的视频

足以支持“文章”？

支持关系存疑

模型结论

supported

“文章”条件得到支持

需要核验事实能否支持结论，而不只是引用是否存在

文章也可能包含视频；仅凭这段响应，不能确认真实定位错误。

来源：实验进度与结果报告 §4 ｜助手对既有响应的审查，不是独立人工语义核验

错误的条件依赖会扩散 unknown

Query： 女子在盆栽旁独白

r1： 独白 → 缺少音频， unknown

响应新增依赖

冻结条件

r3： 植物是否在盆里?
depends_on=[]

模型响应

r3： 因依赖独白而 unknown
但模型事实多次描述 “盆栽”

局部事实独立判断，依赖按冻结合同传播

已确认响应内部不一致；程序传播依赖仍是待验证的修复建议。

内容匹配与时间边界需要分别验证

过长预测：包含大量无关内容

目标事件包含其中

关系示意，无真实时间比例：内容确实出现，区间仍可能因过长而低 IoU 。

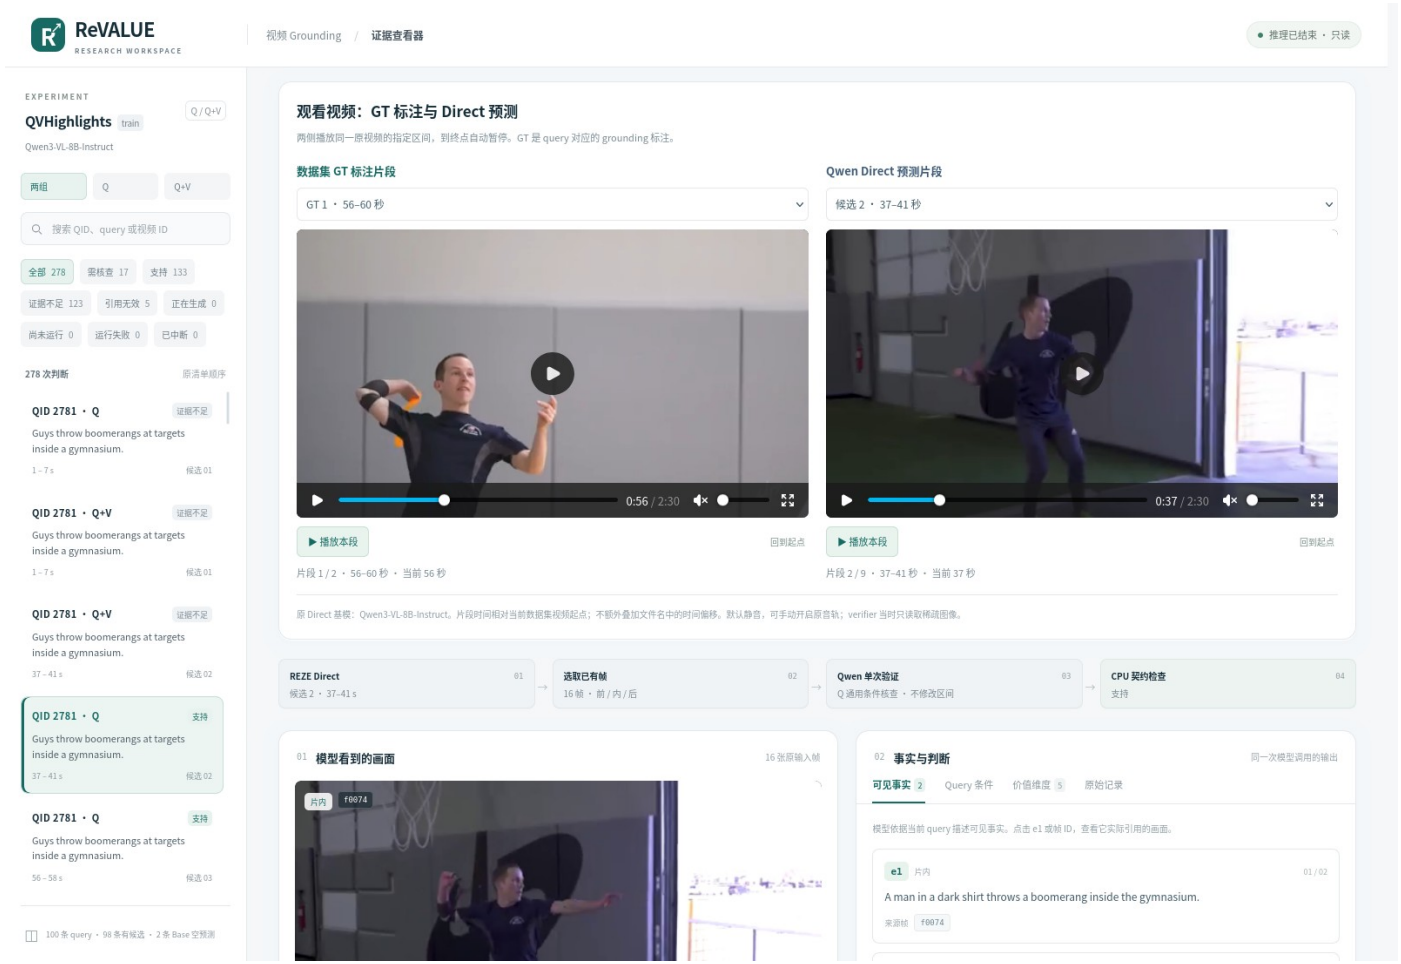
同一 139 候选的 IoU 代理检错权衡 · 引用既有冻结评价

方法	召回率 %	精确率 %	误报数
Q	7.06	85.71	1
Q+V	9.41	80.00	2
冻结时长规则	36.47	77.50	9

时长规则更易发现过长区间，但误报高；当前尚未证明 R1 或 mAP 提升。

来源：实验进度与结果报告 §3.2 、 §4 | semantic-only verifier 尚未验证边界

现在可以直接对照 GT 与 Direct 视频



左：数据集 GT 区间

右：原 Direct 预测

逐段播放、切换候选，
对应查看事实、条件与引用。

使用已有原视频；未改写预测。

8B · 100 query： 8766

32B · 20 query： 8765

两页共用 8B Direct 基线。

GT 为标注参照；目前独立人工语义标签仍为 0 。

来源：本地证据查看器实际截图与视频播放说明（2026-11-03）｜本地访问需 SSH 转发

先查事实与证据，再扩展验证闭环

01 **独立审查：哪些是真正的内容错误**

固定覆盖支持、报警、不足和无效；区分内容、边界、可见性与标注疑点。

02 **单变量诊断：占位示例与结构约束分别检验**

固定旧帧和 query；检查具体事实与正确判断，三卡运行路径另列因素。

03 **事实质量可用后，再判断价值提示的增量**

配对核对 Q / Q+V 的改善和退步；不以更多描述、更多非 NA 作为收益。

04 **有缺证依据后，再做补帧与独立边界验证**

等量均匀 / 定向补证；如改写区间，才进一步评价 R1 与 MR mAP 。

不强迫确定判断。新实验先冻结范围与验收标准；本次仅更新报告和 PPT 。